UNIVERSIDAD TECNOLÓGICA TULA-TEPEJI

Extracción de Conocimiento en Bases de Datos

Actividad de Evaluación – Unidad I

Planeación del Proyecto de Análisis de Datos · Proyecto Integrador de Recursamiento 2026

Proyecto: Análisis del rendimiento académico de estudiantes

Alumna	Brisa Adriana Mendoza Vigueras
Grupo	10IDGS-G1
Docente	Ing. Jose Luis Herrera Gallardo
Fecha	2 de octubre de 2026

Descripción del proyecto

Proyecto	Análisis del rendimiento académico de estudiantes
Asignatura	Extracción de Conocimiento en Bases de Datos (Recursamiento 2026)
Dataset	Student Performance – UCI Machine Learning Repository
Tipo de trabajo	Individual, desarrollado de forma progresiva en las cinco unidades de aprendizaje
Repositorio	https://github.com/menviadriana/REC_ECBD_2026_Mendoza_Brisa

Contexto general

El bajo rendimiento y la reprobación son de los problemas más frecuentes en la educación media superior. Cuando un estudiante reprueba, normalmente se detecta al final del periodo, cuando ya es tarde para intervenir. Las escuelas generan muchos datos sobre sus alumnos (calificaciones parciales, faltas, reprobaciones anteriores) y además pueden obtener información sobre su entorno familiar y social mediante cuestionarios, pero pocas veces esos datos se analizan de forma sistemática para apoyar la toma de decisiones.
El caso asignado utiliza el dataset Student Performance, que reúne información de estudiantes de bachillerato de dos escuelas públicas de Portugal (Gabriel Pereira y Mousinho da Silveira) recopilada durante el ciclo escolar 2005-2006 mediante reportes escolares y cuestionarios (Cortez y Silva, 2008). Para cada alumno se registran sus calificaciones de tres periodos (G1, G2 y G3) junto con variables demográficas, familiares, sociales y de hábitos de estudio.

Descripción del problema

En el sistema educativo portugués las calificaciones van de 0 a 20 y se aprueba con 10 o más. En el curso de Portugués que se analizará, 100 de 649 estudiantes (15.4 %) no aprobaron. El problema consiste en que no se sabe con claridad qué factores, además de las propias calificaciones, están asociados con un bajo desempeño, ni si es posible anticipar la calificación final o el riesgo de reprobar con la información que la escuela ya tiene disponible.

Planteamiento del problema

Situación que se desea analizar. Se quiere analizar la relación entre la calificación final de los estudiantes (G3) y sus características académicas (reprobaciones previas, tiempo de estudio, faltas, calificaciones parciales), familiares (escolaridad y trabajo de los padres, relación familiar, apoyo familiar) y sociales (salidas con amigos, tiempo libre, consumo de alcohol, aspiración a estudios superiores).

Relevancia. Detectar a tiempo a los alumnos en riesgo permite canalizar asesorías, tutorías o apoyo psicopedagógico antes de que el estudiante repruebe o abandone. Además, conocer qué factores pesan más ayuda a priorizar programas de apoyo con recursos limitados.

Necesidad de información. Para apoyar esas decisiones se necesita: (1) identificar qué variables tienen mayor relación con la calificación final; (2) contar con un modelo que estime la calificación final; (3) contar con un modelo que clasifique a los alumnos según su nivel de desempeño o riesgo de reprobar; y (4) conocer qué perfiles o grupos de estudiantes existen y cuál de ellos concentra el mayor riesgo.

Pregunta principal de análisis

¿Qué factores académicos, familiares y sociales influyen en la calificación final de los estudiantes de bachillerato, y en qué medida es posible predecir esa calificación y anticipar el riesgo de reprobación a partir de ellos?

Preguntas secundarias que se derivan de la principal:

¿Qué variables tienen mayor correlación o importancia para explicar G3?

¿Qué tan precisa es la predicción de G3 cuando se usan las calificaciones parciales (G1 y G2) y cuando se usan solo variables personales, familiares y sociales?

¿Es posible clasificar correctamente a los estudiantes que no aprobarán, aun con clases desbalanceadas?

¿Existen grupos de estudiantes con perfiles similares y qué características distinguen al grupo con mayor riesgo?

Objetivo general

Analizar el conjunto de datos Student Performance aplicando la metodología CRISP-DM y técnicas de análisis supervisado y no supervisado con Python, para identificar los factores asociados al rendimiento académico, predecir la calificación final de los estudiantes y clasificar su nivel de desempeño, generando conocimiento que apoye la detección temprana de alumnos en riesgo de reprobación.

Objetivos específicos

- OE1. Elaborar el diccionario de datos de las 33 variables del archivo student-por.csv y realizar un análisis exploratorio (estadística descriptiva, distribuciones y matriz de correlación) que identifique al menos las cinco variables con mayor relación con G3.
- OE2. Limpiar y transformar los datos (tratamiento de registros con G3 = 0, codificación de variables categóricas y escalamiento) mediante un proceso ETL documentado, y cargarlos en un Data Mart en SQL Server con modelo de estrella.
- OE3. Construir y comparar al menos dos modelos de regresión para predecir G3, en dos escenarios (con y sin G1/G2), evaluándolos con MAE, RMSE y R^2.
- OE4. Construir y comparar al menos dos modelos de clasificación para predecir si un estudiante aprueba (G3 ≥ 10) o no, evaluándolos con matriz de confusión, accuracy, precision, recall y F1-score, y aplicar optimización de hiperparámetros con validación cruzada.
- OE5. Aplicar al menos un algoritmo de clustering (K-Means) y una técnica de reducción de dimensionalidad (PCA) para identificar perfiles de estudiantes, evaluando los grupos con el coeficiente de silueta.
- OE6. Presentar los resultados en un dashboard de Power BI con storytelling y publicar todo el desarrollo en el repositorio de GitHub.

Alcance y limitaciones

Alcance (lo que sí se analizará)

- Se trabajará únicamente con el archivo student-por.csv (curso de Portugués): 649 registros y 33 variables.
- Se cubrirá el proceso completo: comprensión del problema, exploración, limpieza, ETL, Data Mart, regresión, clasificación, evaluación y optimización, clustering, PCA y dashboard.
- Los modelos se construirán con scikit-learn y se evaluarán con métricas estándar y validación cruzada.
- El resultado será un análisis y un prototipo de dashboard con fines académicos.

Fuera del alcance

- El archivo student-mat.csv (Matemáticas) no se analizará; solo se conserva en data/raw como parte del paquete original. Tampoco se unirán ambos archivos.
- No se recolectarán datos nuevos ni se agregarán fuentes externas.
- No se implementará el modelo en un sistema escolar real ni se pondrá en producción.
- No se usarán modelos de deep learning, ya que el tamaño del dataset no lo justifica.

Limitaciones

- Tamaño reducido: 649 registros limitan la complejidad de los modelos y aumentan el riesgo de sobreajuste.
- Contexto: los datos corresponden a dos escuelas de Portugal del ciclo 2005-2006, por lo que las conclusiones no pueden generalizarse directamente a otras escuelas o países.
- Datos autorreportados: variables como consumo de alcohol, tiempo de estudio o relación familiar provienen de cuestionarios y pueden tener sesgo.
- Clases desbalanceadas: solo 100 de 649 alumnos no aprobaron, lo que puede hacer que un clasificador ignore la clase minoritaria.
- Fuga de información: G1 y G2 están muy correlacionadas con G3 (0.83 y 0.92); usarlas eleva las métricas pero reduce la utilidad para una detección temprana.
- Correlación no implica causalidad: el análisis identificará asociaciones, no causas.
- Registros con G3 = 0: 15 casos que probablemente corresponden a abandono y no a una calificación real; su tratamiento se decidirá en la Unidad II.

Descripción del conjunto de datos

Nombre	Student Performance
Procedencia	UCI Machine Learning Repository, donado el 26/11/2014. Creador: Paulo Cortez (Universidad do Minho, Portugal). DOI: 10.24432/C5TG7T
Enlace oficial	https://archive.ics.uci.edu/dataset/320/student+performance
Origen de los datos	Reportes escolares y cuestionarios aplicados a estudiantes de secundaria/bachillerato de dos escuelas de Portugal (Cortez y Silva, 2008).
Archivos del paquete	student-por.csv (Portugués, 649 registros), student-mat.csv (Matemáticas, 395 registros), student-merge.R y student.txt (descripción de atributos).
Archivo de trabajo	student-por.csv – formato CSV separado por punto y coma (;)
Tamaño	649 registros × 33 columnas (30 características + G1, G2 y G3)

Tipos de datos	16 variables numéricas enteras (varias son escalas ordinales de 1 a 5) y 17 categóricas (13 binarias sí/no o de dos valores y 4 nominales).
Calidad inicial	0 valores nulos y 0 registros duplicados. 15 registros con G3 = 0.
Distribución de G3	Rango de 0 a 19; media 11.91; mediana 12; desviación estándar 3.23.
Escuelas	GP (Gabriel Pereira): 423 alumnos; MS (Mousinho da Silveira): 226 alumnos.
Copia original	data/raw/ del repositorio, sin modificaciones.

Diccionario preliminar de variables

Variable	Tipo	Descripción y valores
school	Categórica binaria	Escuela: GP (Gabriel Pereira) o MS (Mousinho da Silveira)
sex	Categórica binaria	Sexo: F o M
age	Numérica	Edad del estudiante (15 a 22)
address	Categórica binaria	Domicilio: U (urbano) o R (rural)
famsize	Categórica binaria	Tamaño de la familia: LE3 (≤ 3) o GT3 (> 3)
Pstatus	Categórica binaria	Padres: T (viven juntos) o A (separados)
Medu	Numérica ordinal	Escolaridad de la madre (0 ninguna a 4 educación superior)
Fedu	Numérica ordinal	Escolaridad del padre (0 a 4)
Mjob	Categórica nominal	Trabajo de la madre: teacher, health, services, at_home, other
Fjob	Categórica nominal	Trabajo del padre: mismas categorías que Mjob
reason	Categórica nominal	Motivo de elección de la escuela: home, reputation, course, other
guardian	Categórica nominal	Tutor: mother, father, other
traveltime	Numérica ordinal	Tiempo de traslado a la escuela (1: < 15 min a 4: > 1 h)
studytime	Numérica ordinal	Horas de estudio semanales (1: < 2 h a 4: > 10 h)
failures	Numérica	Materias reprobadas anteriormente (0 a 3; 4 o más se registra como 3)
schoolsup	Categórica binaria	Apoyo educativo adicional de la escuela (yes/no)
famsup	Categórica binaria	Apoyo educativo de la familia (yes/no)
paid	Categórica binaria	Clases extra pagadas de la materia (yes/no)
activities	Categórica binaria	Actividades extracurriculares (yes/no)
nursery	Categórica binaria	Asistió a guardería/preescolar (yes/no)
higher	Categórica binaria	Quiere cursar estudios superiores (yes/no)
internet	Categórica binaria	Internet en casa (yes/no)
romantic	Categórica binaria	Tiene una relación de pareja (yes/no)

Variable	Tipo	Descripción y valores
famrel	Numérica ordinal	Calidad de la relación familiar (1 muy mala a 5 excelente)
freetime	Numérica ordinal	Tiempo libre después de clases (1 a 5)
goout	Numérica ordinal	Salidas con amigos (1 a 5)
Dalc	Numérica ordinal	Consumo de alcohol entre semana (1 a 5)
Walc	Numérica ordinal	Consumo de alcohol en fin de semana (1 a 5)
health	Numérica ordinal	Estado de salud actual (1 a 5)
absences	Numérica	Número de faltas (0 a 32 en este archivo)
G1	Numérica	Calificación del primer periodo (0 a 20)
G2	Numérica	Calificación del segundo periodo (0 a 20)
G3	Numérica	Calificación final (0 a 20) – variable objetivo

Posibles variables objetivo

Regresión	G3 (calificación final, numérica de 0 a 20).
Clasificación	Variable derivada de G3: desempeño aprobado / no aprobado (y como alternativa bajo / medio / alto).
No supervisado	Sin variable objetivo; G3 y la clase derivada solo se usarán para interpretar los grupos obtenidos.

Análisis comparativo: Inteligencia Artificial, Machine Learning, Data Mining y Big Data

Los cuatro conceptos están relacionados, pero no son lo mismo. La Inteligencia Artificial es el campo más amplio; el Machine Learning es una de sus ramas; el Data Mining aplica técnicas estadísticas y de Machine Learning para descubrir patrones dentro de un proceso de extracción de conocimiento (KDD); y el Big Data se refiere a los datos y a la infraestructura necesaria cuando el volumen, la velocidad o la variedad superan a las herramientas tradicionales.

Inteligencia Artificial (IA)

Definición	Campo de la computación que busca crear sistemas capaces de realizar tareas que normalmente requieren inteligencia humana: razonar, aprender, percibir, comprender lenguaje y tomar decisiones (Russell y Norvig, 2021).
Características	Enfoque amplio que incluye sistemas basados en reglas, búsqueda, planificación, lógica, visión por computadora, procesamiento de lenguaje natural y aprendizaje automático. Puede funcionar con conocimiento programado o aprendido de datos.
Beneficios	Automatiza tareas repetitivas o complejas, opera a gran escala y sin descanso, apoya la toma de decisiones y permite crear productos nuevos (asistentes, traductores, vehículos autónomos).
Restricciones	Requiere gran capacidad de cómputo y, en sus enfoques modernos, muchos datos. Los sistemas suelen ser especializados en una tarea y no generalizan como un humano.
Retos	Ética y sesgos, explicabilidad de las decisiones, privacidad, seguridad, regulación y el impacto en el empleo.
Casos de aplicación	Asistentes virtuales y chatbots, reconocimiento facial y de voz, diagnóstico médico por imagen, vehículos autónomos, sistemas tutores inteligentes en educación.
Lenguajes y herramientas	Python, R, Java, C++, Prolog; TensorFlow, PyTorch, Keras, OpenCV, spaCy, servicios en la nube (Azure AI, Google Cloud AI, AWS).

Machine Learning (ML)

Definición	Rama de la IA en la que los sistemas aprenden patrones a partir de datos para hacer predicciones o tomar decisiones sin ser programados explícitamente con reglas (Géron, 2019).
Características	Se divide en aprendizaje supervisado (regresión y clasificación con datos etiquetados), no supervisado (clustering y reducción de dimensionalidad) y por refuerzo. Los modelos se entrenan, se validan y se evalúan con métricas.
Beneficios	Mejora con más datos, descubre relaciones no lineales difíciles de programar a mano, permite predicciones automáticas y se adapta a problemas muy distintos.
Restricciones	Depende de la calidad y cantidad de los datos; los modelos supervisados necesitan datos etiquetados; puede sobreajustarse o subajustarse.
Retos	Selección de variables, desbalance de clases, fuga de información (data leakage), interpretabilidad de los modelos, ajuste de hiperparámetros y mantenimiento de modelos en producción.

Casos de aplicación	Detección de fraude, sistemas de recomendación, filtros de spam, predicción de demanda, predicción del rendimiento académico y del riesgo de deserción (caso de este proyecto).
Lenguajes y herramientas	Python (scikit-learn, XGBoost, TensorFlow), R (caret), Jupyter Notebook, Weka, Azure ML, Google Colab.

Data Mining (Minería de datos)

Definición	Proceso de descubrir patrones, relaciones y conocimiento útil en grandes conjuntos de datos. Es la etapa central del proceso KDD (Knowledge Discovery in Databases) (Fayyad et al., 1996; Han et al., 2012).
Características	Combina estadística, bases de datos y Machine Learning. Sus tareas típicas son clasificación, regresión, agrupamiento, reglas de asociación y detección de anomalías. Sigue metodologías como KDD, CRISP-DM o SEMMA.
Beneficios	Convierte datos históricos en conocimiento para la toma de decisiones, descubre patrones ocultos, apoya la segmentación y la predicción en las organizaciones.
Restricciones	Necesita datos limpios e integrados; los resultados dependen de una buena preparación; los patrones encontrados no siempre son útiles o causales.
Retos	Calidad e integración de datos de distintas fuentes, privacidad, interpretación correcta de los patrones y evitar conclusiones falsas por correlaciones casuales.
Casos de aplicación	Análisis de la canasta de mercado, segmentación de clientes, minería de datos educativa (EDM) para detectar alumnos en riesgo, análisis de riesgo crediticio.
Lenguajes y herramientas	Python (pandas, scikit-learn), R, SQL, RapidMiner, KNIME, Weka, Orange, SQL Server Analysis Services.

Big Data

Definición	Conjuntos de datos tan grandes, rápidos o variados que no pueden procesarse con herramientas tradicionales, así como las tecnologías para almacenarlos y analizarlos (Mayer-Schönberger y Cukier, 2013).
Características	Se describe con las “V”: Volumen, Velocidad, Variedad, Veracidad y Valor. Usa almacenamiento y procesamiento distribuido en clústeres y en la nube.
Beneficios	Permite analizar toda la información disponible y no solo muestras, procesar datos en tiempo real e integrar fuentes estructuradas y no estructuradas (texto, imágenes, sensores, redes sociales).
Restricciones	Requiere infraestructura costosa y personal especializado; no tiene sentido para conjuntos de datos pequeños; mayor complejidad técnica.
Retos	Seguridad y privacidad, gobierno y calidad de los datos, almacenamiento, integración de fuentes heterogéneas y escasez de especialistas.
Casos de aplicación	Análisis de redes sociales, IoT y ciudades inteligentes, recomendaciones en plataformas de streaming, logística, análisis de plataformas educativas en línea con millones de usuarios.

Lenguajes y herramientas	Hadoop (HDFS, MapReduce), Apache Spark (PySpark), Kafka, bases NoSQL (MongoDB, Cassandra), Scala, Java, Python, Databricks, AWS, Azure, Google BigQuery.

Cuadro comparativo resumen

Aspecto	IA	Machine Learning	Data Mining	Big Data
Enfoque	Simular capacidades inteligentes	Aprender de datos para predecir	Descubrir patrones y conocimiento	Gestionar y procesar datos masivos
Pregunta que responde	¿Cómo hacer que una máquina actúe de forma inteligente?	¿Qué pasará? ¿A qué clase pertenece?	¿Qué patrones hay en los datos?	¿Cómo almaceno y proceso tantos datos?
Relación	Campo general	Subcampo de la IA	Usa técnicas de ML y estadística	Infraestructura y fuente de datos para las demás
Volumen de datos	Variable	De cientos a millones	Medianos a grandes	Muy grandes (TB, PB)
Resultado típico	Sistema inteligente	Modelo entrenado	Patrones, reglas, grupos	Plataforma de datos
Herramienta clave	TensorFlow, PyTorch	scikit-learn	KNIME, Weka, Python	Hadoop, Spark

Relación con el proyecto

Este proyecto se ubica principalmente en el Data Mining y el Machine Learning: se seguirá un proceso de extracción de conocimiento (CRISP-DM) y se aplicarán algoritmos de aprendizaje supervisado (regresión y clasificación) y no supervisado (clustering y PCA). Forma parte del campo de la IA, ya que los modelos aprenderán de los datos para apoyar decisiones. En cambio, no es un proyecto de Big Data: con 649 registros y menos de 100 KB, los datos se procesan sin problema en una computadora personal con pandas, por lo que no se justifica usar Hadoop o Spark.

Lenguaje, bibliotecas y herramientas propuestas

Herramienta	Uso en el proyecto	Justificación
Python 3	Lenguaje principal de todo el análisis	Es el lenguaje más usado en ciencia de datos, gratuito y con muchas bibliotecas; es el indicado en la guía del curso.
Jupyter Notebook / VS Code	Desarrollo de notebooks y scripts	Permite combinar código, resultados, gráficas y explicaciones, lo que facilita mostrar y explicar el código en las revisiones.
pandas	Carga, exploración, limpieza y transformación	Lee el CSV con separador “;” y facilita el manejo de tablas, filtros, agrupaciones y estadística descriptiva.

Herramienta	Uso en el proyecto	Justificación
NumPy	Operaciones numéricas	Base de cálculo de pandas y scikit-learn; útil para operaciones con arreglos.
Matplotlib y Seaborn	Gráficas exploratorias	Matplotlib es la biblioteca base indicada en la guía; Seaborn se usará como complemento porque simplifica mapas de calor de correlación, boxplots y gráficas por categoría.
scikit-learn	Regresión, clasificación, clustering, PCA, métricas y optimización	Contiene todos los algoritmos necesarios con una interfaz uniforme, además de pipelines, codificadores, validación cruzada y GridSearchCV (Pedregosa et al., 2011).
SQL Server + SSMS	Data Mart del proyecto	Gestor de base de datos indicado en el curso para el almacén analítico; permite crear el modelo estrella y consultarlo con SQL.
pyodbc / SQLAlchemy	Carga de datos procesados a SQL Server	Permiten conectar Python con SQL Server para automatizar la etapa de carga del ETL.
joblib	Guardar modelos entrenados	Permite guardar los modelos en la carpeta modelos/ y reutilizarlos sin volver a entrenar.
Power BI Desktop	Dashboard final y storytelling	Herramienta indicada en el curso; se conecta directamente a SQL Server y permite crear tableros interactivos.
Git y GitHub	Control de versiones y entrega progresiva	El historial de commits sirve como evidencia del desarrollo por etapas solicitado en la guía.

Metodología de análisis de datos: CRISP-DM

CRISP-DM (Cross Industry Standard Process for Data Mining) es una metodología creada en 1996-2000 por un consorcio de empresas (SPSS, Teradata, Daimler-Chrysler, NCR y OHRA) para guiar proyectos de minería de datos de cualquier industria (Chapman et al., 2000; Wirth y Hipp, 2000). Es la metodología más utilizada en análisis de datos porque es independiente de la herramienta, está orientada al problema del negocio y es iterativa: se puede regresar a etapas anteriores cuando los resultados lo requieren.
Se eligió CRISP-DM sobre otras metodologías como KDD o SEMMA porque empieza por entender el problema (y no solo los datos), incluye explícitamente la evaluación de los resultados frente a los objetivos y su despliegue, y sus seis fases se pueden relacionar directamente con las unidades del curso.

Fase	Descripción	Tareas principales
1. Comprensión del negocio	Entender el problema, los objetivos y los criterios de éxito desde el punto de vista del usuario.	Definir objetivos, evaluar la situación, establecer metas de minería de datos y elaborar el plan del proyecto.
2. Comprensión de los datos	Recolectar los datos y familiarizarse con ellos.	Recolección, descripción, exploración y verificación de la calidad de los datos.

Fase	Descripción	Tareas principales
3. Preparación de los datos	Construir el conjunto de datos final que alimentará a los modelos. Suele ser la fase que más tiempo consume.	Selección, limpieza, construcción de nuevas variables, integración y formateo.
4. Modelado	Seleccionar y aplicar técnicas de modelado y ajustar sus parámetros.	Elegir técnicas, diseñar las pruebas (entrenamiento/prueba), construir y evaluar técnicamente los modelos.
5. Evaluación	Verificar si los modelos cumplen los objetivos del negocio.	Evaluar resultados, revisar el proceso y decidir los siguientes pasos.
6. Despliegue	Poner el conocimiento obtenido a disposición de los usuarios.	Planear la entrega, el monitoreo, elaborar el informe final y revisar el proyecto.

El proceso no es lineal: por ejemplo, si en el modelado se descubre que una variable necesita otra transformación, se regresa a la preparación de datos; y si la evaluación muestra que no se cumplen los objetivos, se vuelve a la comprensión del negocio.
Aplicación de la metodología al proyecto

Fase CRISP-DM	Qué se realizará en este proyecto	Unidad / entregable
1. Comprensión del negocio	Definir el problema del bajo rendimiento, la pregunta de análisis, objetivos, alcance y criterios de éxito. Criterios iniciales: regresión con $R^2 \geq 0.70$ en el escenario con G1/G2; clasificación con recall de la clase “no aprobado” ≥ 0.70.	Unidad I – este documento
2. Comprensión de los datos	Descargar el dataset, conservar la copia original en data/raw, elaborar el diccionario de datos, estadística descriptiva, histogramas, boxplots y matriz de correlación; revisar nulos, duplicados, valores atípicos (absences) y los 15 registros con G3 = 0.	Unidad I (inicial) y revisión Unidad II
3. Preparación de los datos	Decidir el tratamiento de G3 = 0, codificar variables binarias (0/1) y nominales (one-hot), escalar variables numéricas, crear la variable de clase a partir de G3, guardar los archivos en data/processed y cargarlos a un Data Mart en SQL Server con modelo estrella (tabla de hechos de calificaciones y dimensiones de estudiante, familia, escuela y hábitos).	Unidad II
4. Modelado	Supervisado: regresión lineal, Random Forest Regressor (y opcionalmente árbol de decisión) para G3; regresión logística, árbol de decisión y Random Forest para aprobado/no aprobado, con división 80/20 estratificada. No supervisado: K-Means (y opcionalmente clustering jerárquico) y PCA.	Unidades III y IV

Fase CRISP-DM	Qué se realizará en este proyecto	Unidad / entregable
5. Evaluación	Regresión: MAE, RMSE, R^2. Clasificación: matriz de confusión, accuracy, precision, recall, F1. Validación cruzada de 5 particiones y GridSearchCV; manejo del desbalance con class_weight="balanced". Clustering: método del codo, coeficiente de silueta y varianza explicada por PCA. Comparar resultados contra los criterios de éxito.	Unidades III y IV
6. Despliegue	Dashboard en Power BI conectado al Data Mart, con storytelling de los hallazgos; modelos guardados en modelos/; informe final, README completo y defensa del proyecto.	Unidad V

Definición preliminar del análisis supervisado

Regresión

Variable objetivo	G3: calificación final (numérica, 0 a 20).
Escenario A (con G1 y G2)	Predictoras: G1, G2 y el resto de variables. Se espera un error bajo porque G2 tiene una correlación de 0.92 con G3. Útil cuando ya se conocen las calificaciones parciales.
Escenario B (sin G1 y G2)	Predictoras: solo variables personales, familiares y sociales (failures, studytime, higher, Medu, Fedu, school, absences, Dalc, Walc, goout, etc.). Permite una predicción temprana y medir cuánto aportan los factores no académicos.
Modelos propuestos	Regresión lineal múltiple (modelo base interpretable) y Random Forest Regressor (relaciones no lineales e importancia de variables).
Métricas	MAE, RMSE y R^2, con validación cruzada.

Clasificación

La variable de clase se derivará de G3. El criterio de corte se basa en la escala del sistema educativo portugués (0 a 20), donde se aprueba con 10 o más, que es el mismo criterio usado por Cortez y Silva (2008):

Opción	Criterio de corte	Clases y número de registros
Principal: binaria	G3 ≥ 10 → Aprobado (1) G3 < 10 → No aprobado (0)	Aprobado: 549 (84.6 %) No aprobado: 100 (15.4 %)
Alternativa: tres niveles	Bajo: 0 a 9 (no aprobado) Medio: 10 a 13 Alto: 14 a 20	Bajo: 100 (15.4 %) Medio: 355 (54.7 %) Alto: 194 (29.9 %)

Variables predictoras	Las mismas del escenario de regresión; G3 nunca se usará como predictora. Se probará con y sin G1/G2.
Modelos propuestos	Regresión logística, árbol de decisión y Random Forest Classifier.

Desbalance	División estratificada, class_weight="balanced" y, si es necesario, sobremuestreo de la clase minoritaria.
Métricas	Matriz de confusión, accuracy, precision, recall y F1-score. Se dará prioridad al recall de la clase “no aprobado”, porque es más grave no detectar a un alumno en riesgo que dar apoyo a uno que no lo necesitaba.

Análisis no supervisado (Unidad IV)

Se aplicará K-Means sobre las variables académicas y sociales escaladas para encontrar perfiles de estudiantes, eligiendo el número de grupos con el método del codo y el coeficiente de silueta. Se aplicará PCA para reducir la dimensionalidad y visualizar los grupos en dos componentes. G3 no se usará para formar los grupos, solo para interpretarlos (por ejemplo, qué grupo tiene la mayor proporción de no aprobados).

Justificación de las variables

Las variables propuestas son adecuadas porque en la exploración inicial mostraron relación con G3: failures tiene la correlación negativa más fuerte (-0.39); studytime (0.25), Medu (0.24) y Fedu (0.21) tienen correlación positiva; higher, school, Dalc y Walc muestran diferencias en la media de G3. G3 es continua y sirve para regresión; su corte en 10 tiene un significado real (aprobar o no) y sirve para clasificación; y la combinación de variables académicas, familiares y sociales permite formar perfiles en el análisis no supervisado.

Resultados esperados

Un diccionario de datos completo y un análisis exploratorio que identifique las variables más relacionadas con la calificación final.

Un conjunto de datos limpio en data/processed y un Data Mart en SQL Server con modelo estrella.

Un modelo de regresión que estime G3 y una comparación que muestre cuánto mejora la predicción al usar las calificaciones parciales frente a usar solo factores personales y sociales.
Un modelo de clasificación capaz de identificar a la mayoría de los estudiantes que no aprobarán, útil como sistema de alerta temprana.

Un ranking de importancia de variables que indique qué factores (por ejemplo, reprobaciones previas, tiempo de estudio o aspiración a estudios superiores) influyen más en el desempeño.
Perfiles o grupos de estudiantes y la identificación del perfil con mayor riesgo de reprobación.
Un dashboard en Power BI que comunique los hallazgos y recomendaciones para apoyar la toma de decisiones escolares.

Cronograma preliminar del proyecto

Fecha	Etapa oficial	Actividades del proyecto	Fase CRISP-DM
23 sep 2026	Publicación del paquete	Lectura de la guía, asignación del tema y descarga del dataset.	Comprensión del negocio
25 sep 2026	Actividad 0	Registro, primera inspección del dataset y creación del repositorio.	Comprensión de los datos

Fecha	Etapa oficial	Actividades del proyecto	Fase CRISP-DM
2 oct 2026	Unidad I – Planeación (20 %)	Documento de planeación, comparativo, metodología y actualización del README.	Comprensión del negocio
3 – 9 oct 2026	Revisión Unidad II	Diccionario de datos, EDA en notebook, limpieza inicial y propuesta del Data Mart.	Comprensión y preparación de datos
10 – 16 oct 2026	Unidad II – Preparación (15 %)	ETL completo, datos en data/processed, scripts SQL y carga en SQL Server.	Preparación de los datos
17 – 23 oct 2026	Revisión Unidad III	Modelos de regresión y clasificación funcionando.	Modelado
24 – 30 oct 2026	Unidad III – Supervisado (25 %)	Métricas, validación cruzada, optimización e informe.	Modelado y evaluación
31 oct – 6 nov 2026	Revisión Unidad IV	K-Means y PCA funcionando.	Modelado
7 – 13 nov 2026	Unidad IV – No supervisado (25 %)	Evaluación (silueta), interpretación de perfiles e informe.	Modelado y evaluación
14 – 17 nov 2026	Revisión Unidad V	Dashboard y storytelling preliminar en Power BI.	Despliegue
18 – 20 nov 2026	Unidad V y cierre (15 %)	Dashboard final, repositorio final, informe y defensa.	Despliegue

Referencias

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). CRISP-DM 1.0: Step-by-step data mining guide. SPSS Inc

Cortez, P. (2008). Student Performance [Dataset]. UCI Machine Learning Repository. https://doi.org/10.24432/C5TG7T

Cortez, P., & Silva, A. (2008). Using data mining to predict secondary school student performance. En A. Brito & J. Teixeira (Eds.), Proceedings of 5th Future Business Technology Conference (FUBUTEC 2008) (pp. 5–12). EUROSIS.

Fayyad, U., Piatetsky-Shapiro, G., & Smyth, P. (1996). From data mining to knowledge discovery in databases. AI Magazine, 17(3), 37–54.

Géron, A. (2019). Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow (2a ed.). O'Reilly Media.

Han, J., Kamber, M., & Pei, J. (2012). Data mining: Concepts and techniques (3a ed.). Morgan Kaufmann.

Harris, C. R., Millman, K. J., van der Walt, S. J., et al. (2020). Array programming with NumPy. Nature, 585(7825), 357–362. https://doi.org/10.1038/s41586-020-2649-2

Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. Computing in Science & Engineering, 9(3), 90–95.

Kimball, R., & Ross, M. (2013). The data warehouse toolkit: The definitive guide to dimensional modeling (3a ed.). Wiley.

Mayer-Schönberger, V., & Cukier, K. (2013). Big data: A revolution that will transform how we live, work, and think. Houghton Mifflin Harcourt.

McKinney, W. (2010). Data structures for statistical computing in Python. En S. van der Walt & J. Millman (Eds.), Proceedings of the 9th Python in Science Conference (pp. 56–61).

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., et al. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830.

Russell, S., & Norvig, P. (2021). Artificial intelligence: A modern approach (4a ed.). Pearson.

Wirth, R., & Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining. En Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining (pp. 29–39).