UNIVERSIDAD TECNOLÓGICA TULA-TEPEJI

Extracción de Conocimiento en Bases de Datos

Actividad de Evaluación 1 – Unidad II

Exploración, clasificación y diagnóstico del conjunto de datos · Proyecto Integrador de Recursamiento 2026

Proyecto: Análisis del rendimiento académico de estudiantes

Alumna	Brisa Adriana Mendoza Vigueras
Grupo	10IDGS-G1
Docente	Ing. Jose Luis Herrera Gallardo, MTI
Fecha	10 de noviembre de 2026

1. Identificación del dataset

Proyecto	Análisis del rendimiento académico de estudiantes
Dataset	Student Performance
Fuente	UCI Machine Learning Repository. Autor: Paulo Cortez (Universidad do Minho, Portugal). DOI: 10.24432/C5TG7T
Enlace	https://archive.ics.uci.edu/dataset/320/student+performance
Archivo analizado	student-por.csv (curso de Portugués), ubicado sin cambios en data/raw/
Formato	CSV (texto plano separado por punto y coma ";")
Registros	649 (un registro por alumno)
Variables	33: 30 características del alumno + 3 calificaciones (G1, G2 y G3)
Descripción general	Datos de alumnos de bachillerato de dos escuelas públicas de Portugal (Gabriel Pereira y Mousinho da Silveira), ciclo 2005-2006: calificaciones de tres periodos y variables demográficas, familiares, sociales y de hábitos de estudio, obtenidas de reportes escolares y cuestionarios (Cortez y Silva, 2008).
Herramientas	Python 3, Jupyter Notebook en Visual Studio Code, pandas, NumPy y Matplotlib. Notebook: notebooks/Mendoza_Vigueras_Brisa_U2_AE1_Exploracion.ipynb

2. Carga y exploración inicial

El archivo se cargó con pandas indicando el separador punto y coma. El archivo original solo se lee; no se modifica ni se sobrescribe.

```
df = pd.read_csv("../data/raw/student-por.csv", sep=";")
```

Instrucción	Qué hace	Resultado e interpretación
df.head()	Muestra los primeros 5 registros	Cada fila es un alumno y cada columna una característica. Se observan variables de texto (school, sex, Mjob, higher) y numéricas (age, Medu, absences, G1-G3). La carga fue correcta: columnas bien separadas y nombres iguales a la documentación.
df.shape	Devuelve (filas, columnas)	(649, 33): 649 alumnos y 33 variables. Es un dataset pequeño que se procesa sin problema en una computadora personal.
df.columns	Lista los nombres de las variables	Nombres abreviados en inglés (Medu = mother's education, Dalc = daily alcohol), por lo que se requiere un diccionario de datos. No hay nombres repetidos ni con espacios.
df.info()	Tipo de dato y valores no nulos por columna	Las 33 columnas tienen 649 valores no nulos (no hay faltantes). 16 columnas int64 y 17 de texto (object/str). Uso de memoria ≈ 167 KB.
df.dtypes	Tipo de dato de cada variable	Tipos correctos para su contenido. Varias variables int64 no son cantidades, sino escalas ordinales codificadas con números (Medu, studytime, famrel, Dalc, health…): un 4 en studytime significa "más de 10 horas", no "4 horas".

Instrucción	Qué hace	Resultado e interpretación
df.describe()	Estadística descriptiva de variables numéricas (y de texto con exclude='number')	age de 15 a 22 años; G3 de 0 a 19 con media 11.9 (nadie obtuvo 20); el mínimo 0 en G1, G2 y G3 es poco común (ver 5.3); absences tiene media 3.7 pero máximo 32 (posibles atípicos); failures tiene mediana 0. En las categóricas predominan la escuela GP (423), sexo F (383), domicilio urbano (452) y higher = yes (580).

3. Diccionario de datos

Para cada variable se registra su nombre, descripción, tipo de dato en Python, tipo de variable, clasificación, unidad de medida y posible utilidad dentro del proyecto. El tipo de dato en Python se obtuvo directamente con df.dtypes (en pandas 3 el texto aparece como str; en versiones anteriores, como object).

Variable	Descripción	Tipo Python	Tipo	Clasificación	Unidad	Posible utilidad
school	Escuela: GP Gabriel Pereira, MS Mousinho da Silveira	str	Cualitativa	Nominal binaria	No aplica	Comparar desempeño entre escuelas; predictora
sex	Sexo del estudiante (F / M)	str	Cualitativa	Nominal binaria	No aplica	Predictora; segmentación del dashboard
age	Edad del estudiante	int64	Cuantitativa	Discreta	Años	Predictora; edades altas indican rezago
address	Tipo de domicilio: U urbano, R rural	str	Cualitativa	Nominal binaria	No aplica	Predictora (contexto socioeconómico)
famsize	Tamaño de la familia: LE3 (<=3), GT3 (>3)	str	Cualitativa	Ordinal binaria	No aplica	Predictora de entorno familiar
Pstatus	Situación de los padres: T juntos, A separados	str	Cualitativa	Nominal binaria	No aplica	Predictora de entorno familiar
Medu	Escolaridad de la madre (0 ninguna a 4 superior)	int64	Cualitativa	Ordinal	Nivel 0-4	Predictora; correlación positiva con G3
Fedu	Escolaridad del padre (0 ninguna a 4 superior)	int64	Cualitativa	Ordinal	Nivel 0-4	Predictora; correlación positiva con G3
Mjob	Trabajo de la madre (teacher, health, services, at_home, other)	str	Cualitativa	Nominal	No aplica	Predictora (requiere one-hot)
Fjob	Trabajo del padre (mismas categorías)	str	Cualitativa	Nominal	No aplica	Predictora (requiere one-hot)
reason	Motivo de elección de la escuela	str	Cualitativa	Nominal	No aplica	Predictora (requiere one-hot)
guardian	Tutor del estudiante (mother, father, other)	str	Cualitativa	Nominal	No aplica	Predictora (requiere one-hot)
traveltime	Tiempo de traslado (1 <15 min a 4 >1 h)	int64	Cualitativa	Ordinal	Rango de tiempo	Predictora; clustering
studytime	Estudio semanal (1 <2 h a 4 >10 h)	int64	Cualitativa	Ordinal	Rango de horas	Predictora clave; clustering
failures	Materias reprobadas anteriormente (0 a 3)	int64	Cuantitativa	Discreta	Número de materias	Predictora más fuerte fuera de G1/G2

Variable	Descripción	Tipo Python	Tipo	Clasificación	Unidad	Posible utilidad
schoolsup	Apoyo educativo extra de la escuela	str	Cualitativa	Nominal binaria	No aplica	Predictora; indica alumnos en riesgo
famsup	Apoyo educativo de la familia	str	Cualitativa	Nominal binaria	No aplica	Predictora
paid	Clases extra pagadas de la materia	str	Cualitativa	Nominal binaria	No aplica	Predictora
activities	Actividades extracurriculares	str	Cualitativa	Nominal binaria	No aplica	Predictora; clustering
nursery	Asistió a guardería/preescolar	str	Cualitativa	Nominal binaria	No aplica	Predictora (baja relevancia esperada)
higher	Quiere cursar estudios superiores	str	Cualitativa	Nominal binaria	No aplica	Predictora importante (motivación)
internet	Acceso a internet en casa	str	Cualitativa	Nominal binaria	No aplica	Predictora (recursos en casa)
romantic	Tiene relación de pareja	str	Cualitativa	Nominal binaria	No aplica	Predictora; clustering (vida social)
famrel	Calidad de la relación familiar (1 a 5)	int64	Cualitativa	Ordinal	Escala 1-5	Predictora; clustering
freetime	Tiempo libre después de clases (1 a 5)	int64	Cualitativa	Ordinal	Escala 1-5	Predictora; clustering
goout	Salidas con amigos (1 a 5)	int64	Cualitativa	Ordinal	Escala 1-5	Predictora; clustering
Dalc	Consumo de alcohol entre semana (1 a 5)	int64	Cualitativa	Ordinal	Escala 1-5	Predictora; clustering
Walc	Consumo de alcohol en fin de semana (1 a 5)	int64	Cualitativa	Ordinal	Escala 1-5	Predictora; clustering
health	Estado de salud actual (1 a 5)	int64	Cualitativa	Ordinal	Escala 1-5	Predictora
absences	Número de faltas a clase	int64	Cuantitativa	Discreta	Número de faltas	Predictora; clustering
G1	Calificación del primer periodo	int64	Cuantitativa	Discreta	Puntos (0 a 20)	Predictora (escenario con parciales)
G2	Calificación del segundo periodo	int64	Cuantitativa	Discreta	Puntos (0 a 20)	Predictora (escenario con parciales)
G3	Calificación final del curso	int64	Cuantitativa	Discreta	Puntos (0 a 20)	Variable objetivo de regresión; base de la clase aprobado/no aprobado

Clasificación de las variables

Tipo de variable	Clasificación	Cantidad	Variables
Cuantitativa	Discreta	6	age, failures, absences, G1, G2, G3
Cualitativa	Nominal binaria	12	school, sex, address, Pstatus, schoolsup, famsup, paid, activities, nursery, higher, internet, romantic
Cualitativa	Ordinal binaria	1	famsize (LE3 ≤ 3 < GT3)
Cualitativa	Nominal	4	Mjob, Fjob, reason, guardian
Cualitativa	Ordinal	10	Medu, Fedu, traveltime, studytime, famrel, freetime, goout, Dalc, Walc, health

Tipo de variable	Clasificación	Cantidad	Variables
Total		33	

Las variables cuantitativas son discretas porque cuentan unidades enteras (años, materias, faltas, puntos). Las ordinales tienen un orden natural aunque estén codificadas como números, y las binarias y nominales de texto deberán codificarse numéricamente en la etapa de limpieza y transformación.

4. Tipo y fuente de los datos

Los datos fueron recopilados por Cortez y Silva (2008) durante el ciclo escolar 2005-2006 en dos escuelas públicas de Portugal y combinan dos orígenes:

- **Reportes escolares (datos transaccionales o administrativos):** calificaciones G1, G2 y G3, faltas y escuela. Se generan como registro de la operación normal de la escuela: cada evaluación o falta queda capturada en el sistema escolar.
- **Cuestionarios aplicados a los estudiantes (datos generados por personas):** entorno familiar, tiempo de estudio, salidas, consumo de alcohol, aspiraciones, etc. Los reporta el propio alumno, por lo que pueden contener sesgo de autorreporte.

No provienen de máquinas o sensores, de la web, de medios sociales ni son datos biométricos.
Clasificación de la fuente: estructurada. La información está organizada en una tabla de filas (registros) y columnas (variables) definidas, con un tipo de dato fijo por columna, en un archivo CSV. Puede cargarse directamente en pandas o en una base de datos relacional sin interpretar texto libre, a diferencia de los datos semiestructurados (JSON, XML) o no estructurados (texto, imágenes, audio).

5. Diagnóstico de calidad

5.1 Valores faltantes

```
df.isnull().sum()
```

Resultado: **0 valores faltantes en las 33 variables (0 %)**. La instrucción df.info() lo confirma: todas las columnas tienen 649 valores no nulos.
Tratamiento propuesto: no se requiere imputación. Si en una versión futura apareciera algún faltante, las variables numéricas se imputarían con la mediana (por la asimetría de absences) y las categóricas con la moda; solo se eliminarían filas si faltara G3, la variable objetivo.

5.2 Registros duplicados

```
df.duplicated().sum()
```

Resultado: **0 registros duplicados.**
Posible causa si existieran: capturar dos veces al mismo alumno al integrar reportes escolares con cuestionarios, o unir por error este archivo con el de Matemáticas (la documentación indica que 382 alumnos aparecen en ambos). Al trabajar solo con student-por.csv ese riesgo no aplica.
Tratamiento propuesto: de existir duplicados exactos, conservar una sola copia con drop_duplicates() durante la limpieza.

5.3 Valores incorrectos o inconsistentes

Se compararon los datos contra los rangos y categorías válidos de la documentación (student.txt):

Revisión	Resultado
Valores fuera de rango (age 15-22, Medu/Fedu 0-4, escalas 1-4 y 1-5, absences 0-93, G1-G3 0-20)	0 en todas las variables
Valores negativos	0
Categorías inconsistentes (mayúsculas, espacios, valores no documentados)	0: todas las categorías coinciden con la documentación
Tipos de dato incorrectos	Ninguno; solo se documenta que las escalas ordinales están codificadas como enteros
Fechas	No aplica: el dataset no contiene fechas

Al revisar la lógica entre variables sí aparecen casos poco razonables en las calificaciones:

Caso	Registros	Interpretación	Tratamiento propuesto
G3 = 0	15	Todos tienen 0 faltas y calificación en G1 (4 a 11). Lo más probable es que no presentaron la evaluación final (abandono), no que obtuvieran 0.	Marcar con una variable “abandono” y excluirlos del modelado de regresión
G2 = 0	7	Casi todos tienen también G3 = 0: dejaron el curso desde el segundo periodo.	Igual que el caso anterior
G1 = 0 y G3 = 11	1	Tiene 11 en G2 y G3; el 0 en G1 parece un dato no capturado.	Tratarlo como faltante en G1
Documentación de failures	—	student.txt indica que vale n si 1 ≤ n < 3 y si no “4”, pero el máximo en los datos es 3.	Interpretar 3 como “3 o más reprobadas”

6. Análisis estadístico inicial

Variable	Media	Mediana	Mínimo	Máximo	Desv. estándar
G3	11.91	12	0	19	3.23
absences	3.66	2	0	32	4.64
age	16.74	17	15	22	1.22
failures	0.22	0	0	3	0.59
studytime	1.93	2	1	4	0.83

- **G3 (calificación final):** media 11.91 y mediana 12; el alumno típico aprueba (mínimo 10) con poco margen. La desviación de 3.23 indica que la mayoría está entre 9 y 15. El mínimo 0 corresponde a los abandonos.
- **absences (faltas):** la media (3.66) es mayor que la mediana (2), lo que indica una distribución sesgada a la derecha: pocos alumnos con muchas faltas (hasta 32). La desviación (4.64) supera a la media, lo que confirma alta dispersión.
- **age (edad):** media de 16.7 años con poca dispersión (1.22). Las edades de 20 a 22 indican alumnos con rezago escolar.

- **failures (reprobadas previas):** mediana 0 y media 0.22: la gran mayoría nunca ha reprobado. Es la variable con mayor relación negativa con G3.
- **studytime (tiempo de estudio):** mediana 2 (de 2 a 5 horas semanales); pocos alumnos estudian más de 10 horas.

7. Detección inicial de valores atípicos

Se generaron diagramas de caja y se aplicó el criterio del rango intercuartílico (IQR): un valor es atípico si es menor que Q1 − 1.5·IQR o mayor que Q3 + 1.5·IQR.

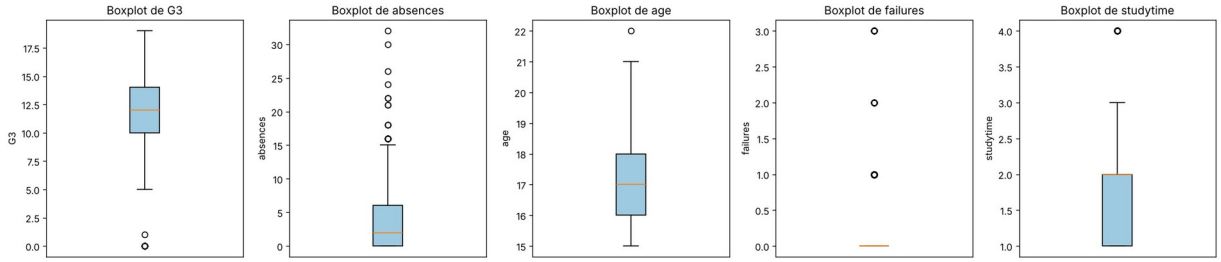


Figura 1. Diagramas de caja de las variables seleccionadas.

Variable	Atípicos (IQR)	Comportamiento	¿Válido o error?	Tratamiento propuesto
G3	16	Valores por debajo de 4: los 15 ceros y un 1	Los ceros representan abandono, no desempeño real	Marcar como abandono y excluir del modelado
absences	21	Más de 15 faltas, máximo 32	Válidos: posibles y dentro del rango documentado (0-93)	No eliminar; recortar a 15 (capping) para el modelado
age	1	Un alumno de 22 años	Válido: rango documentado 15-22	Conservar
failures	100	Como Q1 = Q3 = 0, todo valor > 0 sale como atípico	Válidos: el IQR no es adecuado para una variable tan concentrada	Conservar como variable discreta
studytime	35	Alumnos con valor 4 (más de 10 h)	Válidos: categoría legítima de la escala	Conservar

En esta actividad no se eliminó ningún valor; los tratamientos se aplicarán en la siguiente etapa (limpieza y ETL).

8. Visualización inicial

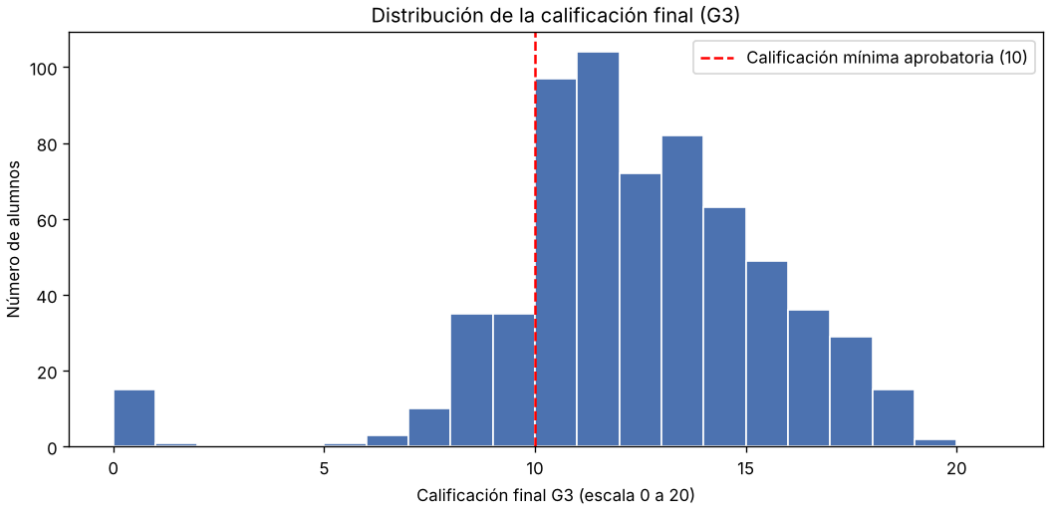


Figura 2. Histograma de la calificación final G3.

Interpretación: la mayoría de los alumnos se concentra entre 10 y 15 puntos, es decir, aprueba. A la izquierda de la línea roja (calificación 10) están quienes no aprobaron, y destaca un grupo aislado en 0 que corresponde a los abandonos detectados.

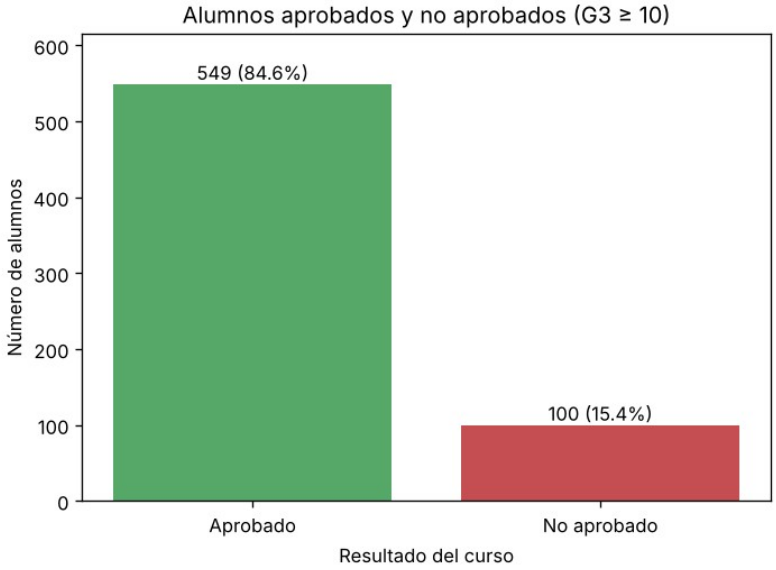


Figura 3. Alumnos aprobados y no aprobados (G3 ≥ 10).

Interpretación: 549 alumnos (84.6 %) aprobaron y 100 (15.4 %) no. Las clases están desbalanceadas: un modelo que dijera “todos aprueban” acertaría el 84.6 % sin detectar a ningún alumno en riesgo, por lo que en la Unidad III se evaluará con recall y F1, no solo con accuracy. La serie aprobado/no aprobado se calculó aparte, sin modificar el DataFrame original.

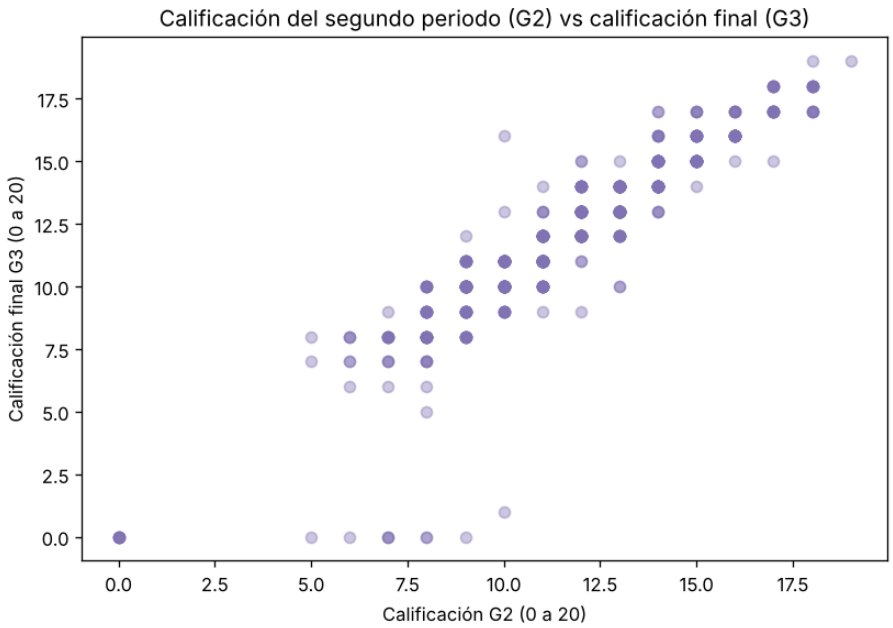


Figura 4. Dispersión entre G2 y la calificación final G3.

Interpretación: los puntos forman casi una línea recta (correlación de 0.92): quien tuvo buena calificación en el segundo periodo casi siempre tiene buena calificación final. Los puntos aislados en G3 = 0 son abandonos. G2 es excelente predictora, pero usarla implica fuga de información, porque cuando se conoce G2 el curso casi terminó.

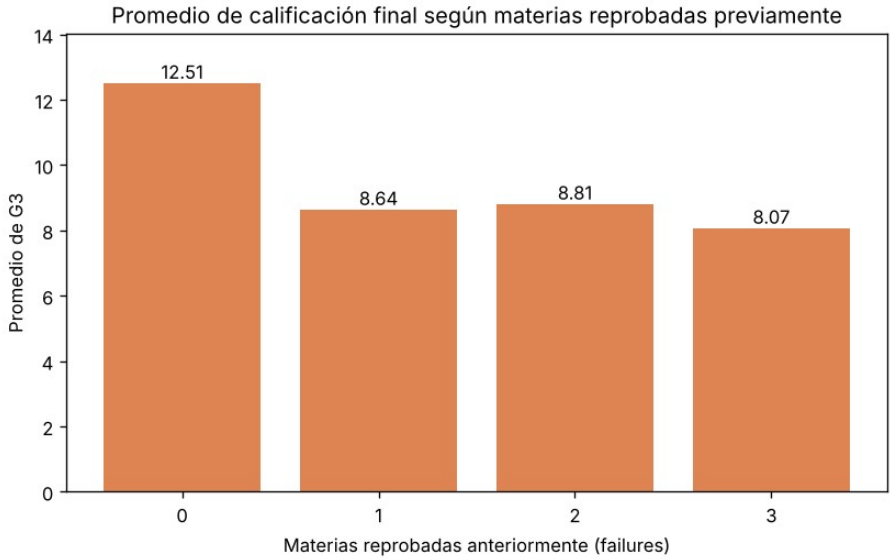


Figura 5. Promedio de G3 según materias reprobadas previamente.

Interpretación: los alumnos sin reprobadas previas promedian 12.51, mientras que quienes reprobaron al menos una vez bajan a menos de 9, por debajo de la calificación aprobatoria. Haber reprobado antes es una señal fuerte de riesgo.

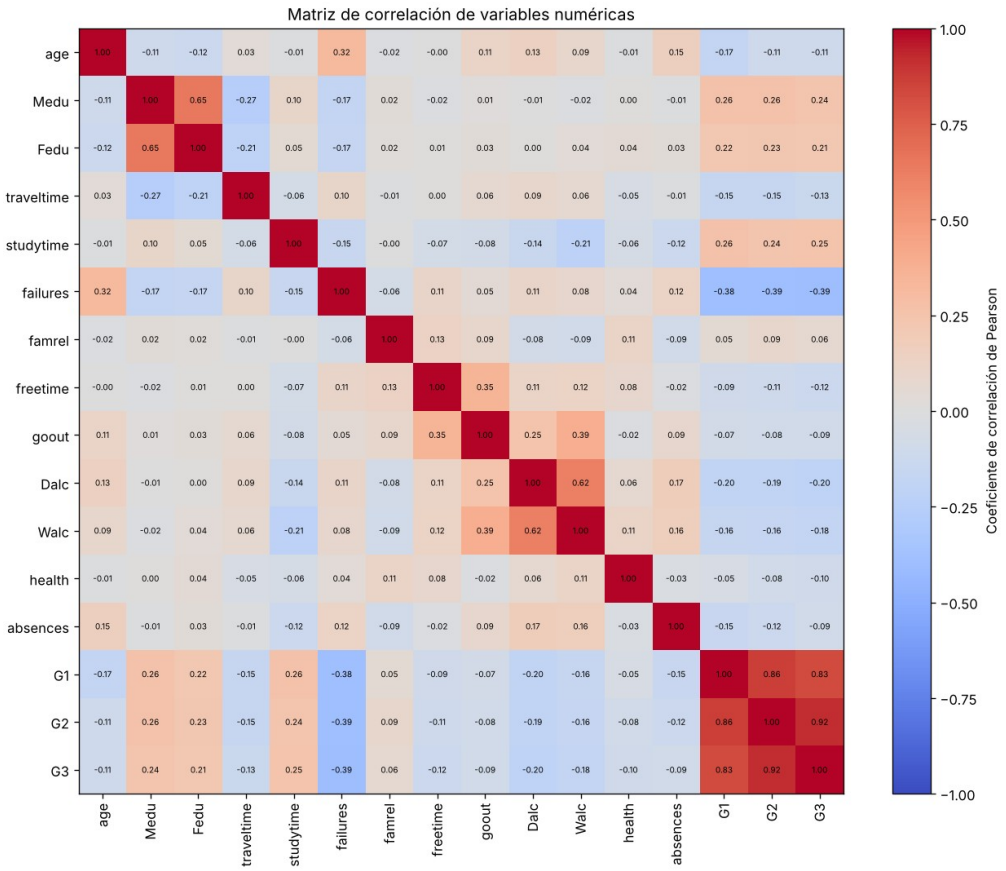


Figura 6. Matriz de correlación de las variables numéricas.

Interpretación: además de G1 (0.83) y G2 (0.92), las variables más relacionadas con G3 son failures (−0.39), studytime (0.25), Medu (0.24), Fedu (0.21), Dalc (−0.20) y Walc (−0.18). Son relaciones moderadas o débiles: ninguna variable personal o social explica por sí sola la calificación. Correlación no implica causalidad.

9. Preparación para análisis posteriores

Análisis	Propuesta	Justificación con el problema de la Unidad I
Regresión	Objetivo: G3 (calificación final, 0 a 20). Entradas: failures, studytime, Medu, Fedu, higher, school, absences, Dalc, Walc, goout, age; en un segundo escenario también G1 y G2.	El proyecto busca anticipar el desempeño final. Comparar los escenarios con y sin calificaciones parciales mide cuánto aportan los factores personales, familiares y sociales.
Clasificación	Objetivo: variable derivada de G3. Clases: Aprobado (G3 ≥ 10) / No aprobado (G3 < 10). Alternativa: Bajo (0-9), Medio (10-13), Alto (14-20).	Responde directamente a la necesidad de detectar a tiempo a los alumnos en riesgo de reprobar. El corte en 10 es la calificación aprobatoria de la escala portuguesa.
Agrupamiento	Variables: studytime, failures, absences, goout, freetime, Dalc, Walc, famrel, Medu, Fedu, health.	Permiten formar perfiles de estudiantes por hábitos, vida social y entorno familiar sin usar la calificación; después, G3 servirá para identificar el grupo con más alumnos en riesgo.

10. Conclusión del diagnóstico

Pregunta	Respuesta
1. ¿Qué información contiene el dataset?	Datos de 649 estudiantes de bachillerato de dos escuelas de Portugal: tres calificaciones del curso de Portugués y 30 características demográficas, familiares, sociales y de hábitos de estudio.
2. ¿Cuál es su nivel general de calidad?	Alto: fuente estructurada, completa, sin duplicados, con valores dentro de los rangos documentados y categorías bien escritas.
3. ¿Qué problemas fueron identificados?	15 alumnos con G3 = 0 (abandono), 7 con G2 = 0, un alumno con G1 = 0 que parece dato no capturado, faltas muy asimétricas con 21 atípicos, clases desbalanceadas (84.6 % / 15.4 %) y variables ordinales codificadas como números.
4. ¿Qué variables requieren tratamiento?	G1, G2 y G3 (casos en cero), absences (atípicos), las 17 variables de texto (codificación) y las numéricas (escalamiento para clustering).
5. ¿Existen valores faltantes?	No: 0 en todas las variables.
6. ¿Existen registros duplicados?	No: 0 registros duplicados.
7. ¿Existen valores atípicos?	Sí, en absences (21) y G3 (16); los detectados en age, failures y studytime son valores válidos.
8. ¿Qué transformaciones serán necesarias?	Marcar abandonos, recortar faltas atípicas, codificar binarias (0/1) y nominales (one-hot), crear la variable de clase (aprobado / nivel de desempeño), escalar variables para clustering y PCA y cargar los datos procesados a un Data Mart.
9. ¿Los datos son adecuados para continuar con el Proyecto Integrador?	Sí: tienen buena calidad, una variable objetivo clara (G3) y variables explicativas relacionadas con ella; los problemas se corrigen con transformaciones sencillas.
10. ¿Qué conocimiento podría obtenerse posteriormente?	Qué factores influyen más en la calificación final (reprobaciones previas, tiempo de estudio, escolaridad de los padres, aspiración a estudios superiores), un modelo de alerta temprana para detectar alumnos en riesgo de reprobar y perfiles de estudiantes para dirigir tutorías y apoyos.

11. Referencias

Cortez, P. (2008). Student Performance [Dataset]. UCI Machine Learning Repository. https://doi.org/10.24432/C5TG7T

Cortez, P., & Silva, A. (2008). Using data mining to predict secondary school student performance. En A. Brito & J. Teixeira (Eds.), Proceedings of 5th Future Business Technology Conference (FUBUTEC 2008) (pp. 5–12). EUROSIS.

Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. Computing in Science & Engineering, 9(3), 90–95.

McKinney, W. (2010). Data structures for statistical computing in Python. En S. van der Walt & J. Millman (Eds.), Proceedings of the 9th Python in Science Conference (pp. 56–61).